


# INCIDENT MANAGEMENT PROCESS ENRICHED EVENT LOG DATA SET

PROJET PYTHON-JORIS CHRISSACHOS



# Pré-requis pour pouvoir lancer le code sur Jupyter

- Pour pouvoir lancer le code , il faut installer les différents packages : `!pip install "le_package"`
- Pour télécharger le dossier complet avec le modèle et le scaler déjà présent dans le fichier de l'API (APIPython/project/ipynb) car fichier trop volumineux pour GITHUB , je vous ai mis un lien vers mon drive dans le mail

# Pré-requis pour pouvoir lancer le code sur Jupyter

- Si vous ne téléchargez le code via le lien de la diapositive précédente , il faut compiler le code(le code à été fait avec un pc 24threads/64GB).
- il y a n\_job à changer en fonction du nombre de thread de son pc
- Pour pouvoir exécuter l'API , il faut mettre le modèle et le scaler dans le dossier (APIPython/project/ipynb)

# Introduction

Ce dataset est un journal des événements des processus de gestion des incidents extrait des données collectées à partir du système d'audit d'une instance de la plateforme ServiceNowTM utilisée par une société informatique.

# Information sur le dataset

Ce dataset comporte 141,712 instances d'événement, 36 attributs pour un total de 24,918 incidents.

Après le calcul de temps entre les logs et la fermeture,nous avons ce type de variable présent dans la dataset:

## Variables types

|      |    |
|------|----|
| CAT  | 29 |
| BOOL | 4  |
| NUM  | 4  |



# Information sur le dataset

Il a fallut nettoyer le dataset car plusieurs variables avait des informations non exploitable.

cmdb\_ci

Categorical

HIGH CARDINALITY

|                |         |
|----------------|---------|
| Distinct count | 51      |
| Unique (%)     | < 0.1%  |
| Missing        | 0       |
| Missing (%)    | 0.0%    |
| Memory size    | 1.1 MiB |

|                   |        |
|-------------------|--------|
| ?                 | 141267 |
| cmdb_ci 31        | 32     |
| cmdb_ci 49        | 24     |
| cmdb_ci 7         | 24     |
| cmdb_ci 11        | 21     |
| Other values (46) | 344    |

rfc

Categorical

HIGH CARDINALITY

|                |         |
|----------------|---------|
| Distinct count | 182     |
| Unique (%)     | 0.1%    |
| Missing        | 0       |
| Missing (%)    | 0.0%    |
| Memory size    | 1.1 MiB |

|                    |        |
|--------------------|--------|
| ?                  | 140721 |
| CHG0000132         | 20     |
| CHG0001230         | 20     |
| CHG0000047         | 18     |
| CHG0001656         | 17     |
| Other values (177) | 916    |

caused\_by

Categorical

|                |         |
|----------------|---------|
| Distinct count | 4       |
| Unique (%)     | < 0.1%  |
| Missing        | 0       |
| Missing (%)    | 0.0%    |
| Memory size    | 1.1 MiB |

|            |        |
|------------|--------|
| ?          | 141689 |
| CHG0000097 | 11     |
| CHG0000132 | 7      |
| CHG0001327 | 5      |

problem\_id

Categorical

HIGH CARDINALITY

|                |         |
|----------------|---------|
| Distinct count | 253     |
| Unique (%)     | 0.2%    |
| Missing        | 0       |
| Missing (%)    | 0.0%    |
| Memory size    | 1.1 MiB |

|                    |        |
|--------------------|--------|
| ?                  | 139417 |
| Problem ID 14      | 184    |
| Problem ID 2       | 147    |
| Problem ID 52      | 82     |
| Problem ID 239     | 48     |
| Other values (248) | 1834   |

vendor

Categorical

|                |         |
|----------------|---------|
| Distinct count | 5       |
| Unique (%)     | < 0.1%  |
| Missing        | 0       |
| Missing (%)    | 0.0%    |
| Memory size    | 1.1 MiB |

|          |        |
|----------|--------|
| ?        | 141468 |
| code 8s  | 167    |
| Vendor 1 | 69     |
| Vendor 3 | 6      |
| Vendor 2 | 2      |



# Calcul du temps restant avant complétion

Pour le calcul du temps restant , j'ai utilisé comme variable "sys\_updated-at" et "closed\_at" pour avoir la différence entre chaque nouveau logs.

il a fallu transformé la date pour pouvoir effectuer une soustraction entre elle pour obtenir des secondes.

$$\text{closed\_at} - \text{sys\_updated\_at} = \text{duree}$$

# Matrice de corrélation



Grâce à la matrice de corrélation, on a pu déterminer quelles variables ont des liens avec les autres



# les Features pour prédire le label(duree)

Pour le choix des features , je me suis basé sur la matrice de corrélation et de quelques variables qui me paraissait importante.

Pour les Features : on a

"active","incident\_state","resolved\_at","opened\_at","number","sys\_mod\_count","u\_priority\_confirmation"

Pour prédire : "duree"

# les Features pour prédire le label(duree)

Pour le choix des features , je me suis basé sur la matrice de corrélation et de quelques variables qui me paraissait importante.

Pour les Features : on a

"active","incident\_state","resolved\_at","opened\_at","number","sys\_mod\_count","u\_priority\_confirmation"

Pour prédire : "duree"

# Les différents modèle de régression

CatBoostRegressor: 34%

DecisionTreeRegressor: 11%

RandomForestRegressor: 10,6%

ExtraTreesRegressor: 46%

XgBoostRegressor: 30%

AdaBoostRegressor: 39%

RandomForestRegressor(avec paramètre optimisé): 48%

Mon choix s'est donc porté l'algorithme de régression RandomForest car cet algorithme à le score de performance le plus élevé

# Mise en place de L'API

Pour la mise en place de l'API , j'ai dû utilisé Joblib pour pouvoir enregistrer le modèle(RandomForestRegressor) ainsi que le scaler.

Mon API se base principalement sur le TD8 disponible sur le github de Luc Bertin.

# L'API fonctionnelle

The screenshot displays the Postman application interface. On the left, a sidebar shows a list of recent POST requests to the endpoint `127.0.0.1:8000/prediction/predict/`. The main workspace is configured for a POST request to the same endpoint. The request body is a JSON object with the following fields:

```
{  "active": 1,  "incident_state": 7,  "resolved_at": 1456741740,  "opened_at": 1456704960,  "number": 0,  "sys_mod_count": 0,  "u_priority_confirmation": 0,  "duree": null}
```

The response tab at the bottom shows a status of 201 Created, a time of 552ms, and a size of 362 B. The response body is a JSON object:

```
{"active": 1.0, "incident_state": 7.0, "resolved_at": 1456741740.0, "opened_at": 1456704960.0, "number": 0.0, "sys_mod_count": 0.0, "u_priority_confirmation": 0.0, "duree": 28662.0}
```

# L'API

On peut voir dans la précédente diapositive que l'api fonctionne car elle nous renvoie bien une prédiction de duree pour la résolution de l'incident.



# Conclusion

Ce projet était très intéressant malgré le fait que la distance entre le cours vu et le projet est assez important.

Cependant j'ai réussi à réaliser plusieurs prédictions sous différents algorithmes de régression avec une performance qui n'est pas optimale mais convenable.

L'API est fonctionnelle et retourne bien des prédictions en fonction du modèle de régression choisi.

Je voulais vous remercier pour ce projet, qui malgré la difficulté a été très enrichissant.